


SETEMBRO/2026

Hello World LLM!

Consumindo APIs, Contexto e Conceitos Básicos

RocketLab 26.2

v(dev)



Como uma LLM funciona

O modelo não entende a frase. Ele calcula **qual token vem a seguir** e repete isso, um token por vez.

“Hoje o dia está ____”

O modelo devolve uma distribuição de probabilidade sobre TODOS os tokens possíveis com base nas palavras anteriores. Depois, "escolhe" um.



Existem parâmetros que podemos definir que afetam como esse "sorteio" da próxima palavra acontece.

Parâmetros de Geração

Temperature

Controla a aleatoriedade (criatividade) do modelo. Varia de 0.0 a 1.0 ou 2.0. Valores menores são determinísticos; maiores são criativos.

Top-K & Top-P

Top-K: limita entre quantos tokens o modelo escolhe.

Top-P: Mede criatividade olhando para a probabilidade acumulada. Na prática, mexa só na temperature.

System Prompt

Atua como diretriz mestre do sistema. O modelo dá prioridade máxima a este comando.

Os mesmos parâmetros, na prática

Dado o mesmo prompt: **"Complete: Hoje o dia está"**

temperature = 0

Dá preferência ao token mais provável. Escolha quando queira uma saída consistente.

"Hoje o dia está ensolarado."

temperature = 1.8

Sorteio mais frouxo: tokens improváveis são mais escolhidos. Criativo, e diferente a cada chamada.

"Hoje o dia está pedindo um algodão doce."

system_instruction = "seja um poeta pessimista"

O sorteio é o mesmo. O que mudou foi o contexto que entra antes da pergunta.

"Hoje o dia está cinzento, como quase todos."

Contexto em LLMs

O que é a Janela de Contexto?

É a **quantidade de texto (tokens)** que o modelo consegue processar de uma vez.

O que é um Token?

Fragmento de texto ($\sim \frac{3}{4}$ de palavra). 1 token $\approx$ 4 caracteres em inglês. Na prática, **a cada 100 tokens, temos de 60 a 80 palavras.**

O que ocupa o contexto?



Prompt do Sistema



Histórico da Conversa



Documentos Anexados



Passos Intermediários

Evolução da Janela de Contexto dos LLMs

4K

GPT-3 (2020)

16K

GPT-3.5 Turbo

128K

Llama 3.1 / GPT-4

200K

Claude 3.5 Sonnet

2M

Gemini 1.5 Pro

10M

Llama 4



Atenção:

O "contexto efetivo" costuma ser menor que a janela anunciada. Itens no meio do contexto são menos lembrados (lost-in-the-middle).

Roles e Formatos de Mensagens

O Gemini utiliza um padrão de hierarquia de mensagens baseado em **papéis (roles)** para manter o histórico de contexto e gerar respostas coerentes.



Padrão Nativo Gemini

Focado em duas roles principais: **user** (usuário final) e **model** (a IA).



Compatibilidade OpenAI

Grande parte das APIs, como a Google, dá suporte às roles "system", "user" e "assistant", definida pela OpenAI.

```
"contents": [  
  {  
    "role": "user",  
    "parts": [  
      // A list of Part objects goes here  
    ]  
  },  
  {  
    "role": "model",  
    "parts": [  
      // A list of Part objects goes here  
    ]  
  }  
]
```

Nível de Raciocínio

Sem raciocínio

Hoje, todos os modelos mais recentes possuem algum nível de raciocínio configurável



Prompt do Usuário

Entrada de dados da requisição.



Previsão de Tokens

Reconhecimento de padrões em passagem única (Single-pass).



Resposta Padrão

Saída gerada baseada em probabilidade estatística direta.

Latência: Baixa

Custo: Baixo

Precisão: Média

Coerência: Média

Com raciocínio

thinking_level: minimal, low, medium, high



Prompt do Usuário

Entrada de problema complexo.



- 1 Estruturação Lógica e Entendimento do Problema
- 2 Planejamento e Avaliação de Caminhos
- 3 Checagem de coerência e correteude da resposta



Resposta Otimizada

Saída validada com alta precisão técnica e analítica.

Latência: Alta

Custo: Alto

Precisão: Alta


Coerência: Alta

Function Calling

Para expandir suas capacidades, os modelos podem **utilizar funções externas ou definidas por você**.

Como LLMs, que geram texto, chamam funções?

Basta ensinar ao modelo a estrutura para chamar a função desejada e depois executar a função. Por exemplo:



Não deixe de responder nosso
formulário de avaliação!



v(dev)